

Μείωση διάστασης στην παλινδρόμηση

Δημήτρης Κουγιουμτζής

17 Δεκεμβρίου 2019

Για τη μείωση μεταβλητών εισόδου σε μοντέλα παλινδρόμησης:

Για τη μείωση μεταβλητών εισόδου σε μοντέλα παλινδρόμησης:

1. Γραμμικοί μετασχηματισμοί:

- παλινδρόμηση κύριων συνιστωσών (principal component regression),
- παλινδρόμηση με μερικά ελάχιστα τετράγωνα (partial least squares regression).

Για τη μείωση μεταβλητών εισόδου σε μοντέλα παλινδρόμησης:

1. Γραμμικοί μετασχηματισμοί:

- παλινδρόμηση κύριων συνιστωσών (principal component regression),
- παλινδρόμηση με μερικά ελάχιστα τετράγωνα (partial least squares regression).

2. Τεχνικές στάθμισης μεταβλητών:

- παλινδρόμηση ridge

Για τη μείωση μεταβλητών εισόδου σε μοντέλα παλινδρόμησης:

1. Γραμμικοί μετασχηματισμοί:
 - παλινδρόμηση κύριων συνιστωσών (principal component regression),
 - παλινδρόμηση με μερικά ελάχιστα τετράγωνα (partial least squares regression).
2. Τεχνικές στάθμισης μεταβλητών:
 - παλινδρόμηση ridge
3. Τεχνικές επιλογής μεταβλητών:
 - βηματική παλινδρόμηση,
 - LASSO.

Πολλαπλή γραμμική παλινδρόμηση

Y : εξαρτημένη μεταβλητή (μεταβλητή απόκρισης)

X_1, X_2, \dots, X_K : K ανεξάρτητες (επεξηγηματικές) μεταβλητές

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_K X_K + \epsilon,$$

$$E[\epsilon] = 0, \quad \sigma_\epsilon^2 = \text{Var}[\epsilon]$$

Πολλαπλή γραμμική παλινδρόμηση

Y : εξαρτημένη μεταβλητή (μεταβλητή απόκρισης)

X_1, X_2, \dots, X_K : K ανεξάρτητες (επεξηγηματικές) μεταβλητές

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_K X_K + \epsilon,$$

$$E[\epsilon] = 0, \quad \sigma_e^2 = \text{Var}[\epsilon]$$

Προσοχή στην ύπαρξη πολυ-συγγραμμικότητας multiple collinearity (multicollinearity):

κάποιες από τις X_1, X_2, \dots, X_K είναι ισχυρά συσχετισμένες.

Πολλαπλή γραμμική παλινδρόμηση

Y : εξαρτημένη μεταβλητή (μεταβλητή απόκρισης)

X_1, X_2, \dots, X_K : K ανεξάρτητες (επεξηγηματικές) μεταβλητές

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k + \epsilon,$$

$$E[\epsilon] = 0, \quad \sigma_e^2 = \text{Var}[\epsilon]$$

Προσοχή στην ύπαρξη πολυ-συγγραμμικότητας multiple collinearity (multicollinearity):

κάποιες από τις X_1, X_2, \dots, X_K είναι ισχυρά συσχετισμένες.

Πρώτη προσέγγιση: βηματική παλινδρόμηση (stepwise regression) αλλά...

Πολλαπλή γραμμική παλινδρόμηση

Y : εξαρτημένη μεταβλητή (μεταβλητή απόκρισης)

X_1, X_2, \dots, X_K : K ανεξάρτητες (επεξηγηματικές) μεταβλητές

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_K X_K + \epsilon,$$

$$E[\epsilon] = 0, \quad \sigma_\epsilon^2 = \text{Var}[\epsilon]$$

Προσοχή στην ύπαρξη πολυ-συγγραμμικότητας multiple collinearity (multicollinearity):

κάποιες από τις X_1, X_2, \dots, X_K είναι ισχυρά συσχετισμένες.

Πρώτη προσέγγιση: **βηματική παλινδρόμηση (stepwise regression)** αλλά...
τείνει να υπερ-προσαρμόζεται στα δεδομένα (καλύτερη προσαρμογή στο δείγμα εκμάθησης αλλά χειρότερη πρόβλεψη σε νέο σύνολο δεδομένων).

Μετασχηματισμός και προβολή

Y : εξαρτημένη μεταβλητή και παρατηρήσεις της: $\mathbf{y} = [y_1, \dots, y_n]^T$

X_1, X_2, \dots, X_K : K ανεξάρτητες μεταβλητές και παρατηρήσεις τους:

$n \times K$ πίνακας δεδομένων $X = [\mathbf{x}_1, \dots, \mathbf{x}_K]$

Μετασχηματισμός και προβολή

Y : εξαρτημένη μεταβλητή και παρατηρήσεις της: $\mathbf{y} = [y_1, \dots, y_n]^T$

X_1, X_2, \dots, X_K : K ανεξάρτητες μεταβλητές και παρατηρήσεις τους:

$n \times K$ πίνακας δεδομένων $X = [\mathbf{x}_1, \dots, \mathbf{x}_K]$

Μοντέλο γραμμικής παλινδρόμησης: $\mathbf{y} = X\mathbf{b} + \epsilon$, ϵ τυχαίο σφάλμα

Μετασχηματισμός και προβολή

Y : εξαρτημένη μεταβλητή και παρατηρήσεις της: $\mathbf{y} = [y_1, \dots, y_n]^T$

X_1, X_2, \dots, X_K : K ανεξάρτητες μεταβλητές και παρατηρήσεις τους:
 $n \times K$ πίνακας δεδομένων $X = [\mathbf{x}_1, \dots, \mathbf{x}_K]$

Μοντέλο γραμμικής παλινδρόμησης: $\mathbf{y} = X\mathbf{b} + \epsilon$, ϵ τυχαίο σφάλμα

Ανάλυση ιδιάζουσων τιμών (SVD) του X : $X = U\Sigma V^T$,

$U^T U = I_n$, $V^T V = I_r$, $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_r)$, $r = \min(n, K)$ τάξη του X

Μετασχηματισμός και προβολή

Y : εξαρτημένη μεταβλητή και παρατηρήσεις της: $\mathbf{y} = [y_1, \dots, y_n]^T$

X_1, X_2, \dots, X_K : K ανεξάρτητες μεταβλητές και παρατηρήσεις τους:
 $n \times K$ πίνακας δεδομένων $X = [\mathbf{x}_1, \dots, \mathbf{x}_K]$

Μοντέλο γραμμικής παλινδρόμησης: $\mathbf{y} = X\mathbf{b} + \epsilon$, ϵ τυχαίο σφάλμα

Ανάλυση ιδιάζουσων τιμών (SVD) του X : $X = U\Sigma V^T$,

$U^T U = I_n$, $V^T V = I_r$, $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_r)$, $r = \min(n, K)$ τάξη του X

Λύση ελαχίστων τετραγώνων (ordinary least squares (OLS)):

Μετασχηματισμός και προβολή

Y : εξαρτημένη μεταβλητή και παρατηρήσεις της: $\mathbf{y} = [y_1, \dots, y_n]^T$

X_1, X_2, \dots, X_K : K ανεξάρτητες μεταβλητές και παρατηρήσεις τους:

$n \times K$ πίνακας δεδομένων $X = [\mathbf{x}_1, \dots, \mathbf{x}_K]$

Μοντέλο γραμμικής παλινδρόμησης: $\mathbf{y} = X\mathbf{b} + \epsilon$, ϵ τυχαίο σφάλμα

Ανάλυση ιδιάζουσων τιμών (SVD) του X : $X = U\Sigma V^T$,

$U^T U = I_n$, $V^T V = I_r$, $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_r)$, $r = \min(n, K)$ τάξη του X

Λύση ελαχίστων τετραγώνων (ordinary least squares (OLS)):

$$\mathbf{b}_{\text{OLS}} = V\Sigma^{-1}U^T\mathbf{y} = \sum_{i=1}^r \frac{1}{\sigma_i}(\mathbf{u}_i^T\mathbf{y})\mathbf{v}_i$$

Μετασχηματισμός και προβολή

Y : εξαρτημένη μεταβλητή και παρατηρήσεις της: $\mathbf{y} = [y_1, \dots, y_n]^T$

X_1, X_2, \dots, X_K : K ανεξάρτητες μεταβλητές και παρατηρήσεις τους:

$n \times K$ πίνακας δεδομένων $X = [\mathbf{x}_1, \dots, \mathbf{x}_K]$

Μοντέλο γραμμικής παλινδρόμησης: $\mathbf{y} = X\mathbf{b} + \epsilon$, ϵ τυχαίο σφάλμα

Ανάλυση ιδιάζουσων τιμών (SVD) του X : $X = U\Sigma V^T$,

$U^T U = I_n$, $V^T V = I_r$, $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_r)$, $r = \min(n, K)$ τάξη του X

Λύση ελαχίστων τετραγώνων (ordinary least squares (OLS)):

$$\mathbf{b}_{\text{OLS}} = V\Sigma^{-1}U^T\mathbf{y} = \sum_{i=1}^r \frac{1}{\sigma_i}(\mathbf{u}_i^T\mathbf{y})\mathbf{v}_i$$

Κανονικοποίηση (regularization) της λύσης OLS για \mathbf{b}

Μετασχηματισμός και προβολή

Y : εξαρτημένη μεταβλητή και παρατηρήσεις της: $\mathbf{y} = [y_1, \dots, y_n]^T$

X_1, X_2, \dots, X_K : K ανεξάρτητες μεταβλητές και παρατηρήσεις τους:

$n \times K$ πίνακας δεδομένων $X = [\mathbf{x}_1, \dots, \mathbf{x}_K]$

Μοντέλο γραμμικής παλινδρόμησης: $\mathbf{y} = X\mathbf{b} + \epsilon$, ϵ τυχαίο σφάλμα

Ανάλυση ιδιάζουσων τιμών (SVD) του X : $X = U\Sigma V^T$,

$U^T U = I_n$, $V^T V = I_r$, $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_r)$, $r = \min(n, K)$ τάξη του X

Λύση ελαχίστων τετραγώνων (ordinary least squares (OLS)):

$$\mathbf{b}_{\text{OLS}} = V\Sigma^{-1}U^T\mathbf{y} = \sum_{i=1}^r \frac{1}{\sigma_i}(\mathbf{u}_i^T\mathbf{y})\mathbf{v}_i$$

Κανονικοποίηση (regularization) της λύσης OLS για \mathbf{b}

$$\mathbf{b} = V\Sigma^{-1}\Lambda U^T\mathbf{y} = \sum_{i=1}^r \frac{\lambda_i}{\sigma_i}(\mathbf{u}_i^T\mathbf{y})\mathbf{v}_i$$

Μετασχηματισμός και προβολή

Y : εξαρτημένη μεταβλητή και παρατηρήσεις της: $\mathbf{y} = [y_1, \dots, y_n]^T$

X_1, X_2, \dots, X_K : K ανεξάρτητες μεταβλητές και παρατηρήσεις τους:

$n \times K$ πίνακας δεδομένων $X = [\mathbf{x}_1, \dots, \mathbf{x}_K]$

Μοντέλο γραμμικής παλινδρόμησης: $\mathbf{y} = X\mathbf{b} + \epsilon$, ϵ τυχαίο σφάλμα

Ανάλυση ιδιάζουσων τιμών (SVD) του X : $X = U\Sigma V^T$,

$U^T U = I_n$, $V^T V = I_r$, $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_r)$, $r = \min(n, K)$ τάξη του X

Λύση ελαχίστων τετραγώνων (ordinary least squares (OLS)):

$$\mathbf{b}_{\text{OLS}} = V\Sigma^{-1}U^T\mathbf{y} = \sum_{i=1}^r \frac{1}{\sigma_i}(\mathbf{u}_i^T\mathbf{y})\mathbf{v}_i$$

Κανονικοποίηση (regularization) της λύσης OLS για \mathbf{b}

$$\mathbf{b} = V\Sigma^{-1}\Lambda U^T\mathbf{y} = \sum_{i=1}^r \frac{\lambda_i}{\sigma_i}(\mathbf{u}_i^T\mathbf{y})\mathbf{v}_i$$

όπου $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_r)$ λέγονται παράγοντες φίλτρου (filter factors)

Μετασχηματισμός και προβολή

Y : εξαρτημένη μεταβλητή και παρατηρήσεις της: $\mathbf{y} = [y_1, \dots, y_n]^T$

X_1, X_2, \dots, X_K : K ανεξάρτητες μεταβλητές και παρατηρήσεις τους:

$n \times K$ πίνακας δεδομένων $X = [\mathbf{x}_1, \dots, \mathbf{x}_K]$

Μοντέλο γραμμικής παλινδρόμησης: $\mathbf{y} = X\mathbf{b} + \epsilon$, ϵ τυχαίο σφάλμα

Ανάλυση ιδιάζουσων τιμών (SVD) του X : $X = U\Sigma V^T$,

$U^T U = I_n$, $V^T V = I_r$, $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_r)$, $r = \min(n, K)$ τάξη του X

Λύση ελαχίστων τετραγώνων (ordinary least squares (OLS)):

$$\mathbf{b}_{\text{OLS}} = V\Sigma^{-1}U^T\mathbf{y} = \sum_{i=1}^r \frac{1}{\sigma_i}(\mathbf{u}_i^T\mathbf{y})\mathbf{v}_i$$

Κανονικοποίηση (regularization) της λύσης OLS για \mathbf{b}

$$\mathbf{b} = V\Sigma^{-1}\Lambda U^T\mathbf{y} = \sum_{i=1}^r \frac{\lambda_i}{\sigma_i}(\mathbf{u}_i^T\mathbf{y})\mathbf{v}_i$$

όπου $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_r)$ λέγονται παράγοντες φίλτρου (filter factors)

Μείωση διάστασης \equiv κανονικοποίηση της λύσης του \mathbf{b}

Μετασχηματισμός και προβολή

Y : εξαρτημένη μεταβλητή και παρατηρήσεις της: $\mathbf{y} = [y_1, \dots, y_n]^T$

X_1, X_2, \dots, X_K : K ανεξάρτητες μεταβλητές και παρατηρήσεις τους:

$n \times K$ πίνακας δεδομένων $X = [\mathbf{x}_1, \dots, \mathbf{x}_K]$

Μοντέλο γραμμικής παλινδρόμησης: $\mathbf{y} = X\mathbf{b} + \epsilon$, ϵ τυχαίο σφάλμα

Ανάλυση ιδιάζουσων τιμών (SVD) του X : $X = U\Sigma V^T$,

$U^T U = I_n$, $V^T V = I_r$, $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_r)$, $r = \min(n, K)$ τάξη του X

Λύση ελαχίστων τετραγώνων (ordinary least squares (OLS)):

$$\mathbf{b}_{\text{OLS}} = V\Sigma^{-1}U^T\mathbf{y} = \sum_{i=1}^r \frac{1}{\sigma_i}(\mathbf{u}_i^T\mathbf{y})\mathbf{v}_i$$

Κανονικοποίηση (regularization) της λύσης OLS για \mathbf{b}

$$\mathbf{b} = V\Sigma^{-1}\Lambda U^T\mathbf{y} = \sum_{i=1}^r \frac{\lambda_i}{\sigma_i}(\mathbf{u}_i^T\mathbf{y})\mathbf{v}_i$$

όπου $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_r)$ λέγονται παράγοντες φίλτρου (filter factors)

Μείωση διάστασης \equiv κανονικοποίηση της λύσης του \mathbf{b}

Οι μέθοδοι κανονικοποίησης εισάγουν μεροληψία στην λύση OLS του \mathbf{b} αλλά μειώνει τη διασπορά.

Παλινδρόμηση κύριων συνιστωσών

Η παλινδρόμηση κύριων συνιστωσών (principal component regression, PCR) βασίζεται στην ανάλυση κύριων συνιστωσών (PCA):

Παλινδρόμηση κύριων συνιστωσών

Η παλινδρόμηση κύριων συνιστωσών (principal component regression, PCR) βασίζεται στην ανάλυση κύριων συνιστωσών (PCA):

1. Περιστροφή της φυσικής βάσης του \mathbf{R}^K : με PCA (ή SVD) υπολογίζονται οι K κύριες συνιστώσες (principal components, PCs), $\mathbf{X} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$ (όπως για OLS).

Παλινδρόμηση κύριων συνιστωσών

Η παλινδρόμηση κύριων συνιστωσών (principal component regression, PCR) βασίζεται στην ανάλυση κύριων συνιστωσών (PCA):

1. Περιστροφή της φυσικής βάσης του \mathbf{R}^K : με PCA (ή SVD) υπολογίζονται οι K κύριες συνιστώσες (principal components, PCs), $\mathbf{X} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$ (όπως για OLS).
2. Προβολή στον υποχώρο \mathbf{R}^k , $k \leq r$: Επιλέγονται οι k πρώτες PCs από κάποιο κριτήριο, π.χ. ποσοστό διασποράς που εξηγείται.

Παλινδρόμηση κύριων συνιστωσών

Η παλινδρόμηση κύριων συνιστωσών (principal component regression, PCR) βασίζεται στην ανάλυση κύριων συνιστωσών (PCA):

1. Περιστροφή της φυσικής βάσης του \mathbf{R}^K : με PCA (ή SVD) υπολογίζονται οι K κύριες συνιστώσες (principal components, PCs), $\mathbf{X} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$ (όπως για OLS).
2. Προβολή στον υποχώρο \mathbf{R}^k , $k \leq r$: Επιλέγονται οι k πρώτες PCs από κάποιο κριτήριο, π.χ. ποσοστό διασποράς που εξηγείται.
3. Εκτίμηση του μοντέλου παλινδρόμησης στις επιλεγμένες k PCs και εύρεση του διανύσματος συντελεστών.

Παλινδρόμηση κύριων συνιστωσών

Η παλινδρόμηση κύριων συνιστωσών (principal component regression, PCR) βασίζεται στην ανάλυση κύριων συνιστωσών (PCA):

1. Περιστροφή της φυσικής βάσης του \mathbf{R}^K : με PCA (ή SVD) υπολογίζονται οι K κύριες συνιστώσες (principal components, PCs), $\mathbf{X} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$ (όπως για OLS).
2. Προβολή στον υποχώρο \mathbf{R}^k , $k \leq r$: Επιλέγονται οι k πρώτες PCs από κάποιο κριτήριο, π.χ. ποσοστό διασποράς που εξηγείται.
3. Εκτίμηση του μοντέλου παλινδρόμησης στις επιλεγμένες k PCs και εύρεση του διανύσματος συντελεστών.
4. Μετασχηματισμός του διανύσματος συντελεστών πίσω στον αρχικό χώρο των K ανεξάρτητων μεταβλητών.

Παλινδρόμηση κύριων συνιστωσών

Η παλινδρόμηση κύριων συνιστωσών (principal component regression, PCR) βασίζεται στην ανάλυση κύριων συνιστωσών (PCA):

1. Περιστροφή της φυσικής βάσης του \mathbf{R}^K : με PCA (ή SVD) υπολογίζονται οι K κύριες συνιστώσες (principal components, PCs), $\mathbf{X} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$ (όπως για OLS).
2. Προβολή στον υποχώρο \mathbf{R}^k , $k \leq r$: Επιλέγονται οι k πρώτες PCs από κάποιο κριτήριο, π.χ. ποσοστό διασποράς που εξηγείται.
3. Εκτίμηση του μοντέλου παλινδρόμησης στις επιλεγμένες k PCs και εύρεση του διανύσματος συντελεστών.
4. Μετασχηματισμός του διανύσματος συντελεστών πίσω στον αρχικό χώρο των K ανεξάρτητων μεταβλητών.

Η εκτίμηση PCR του \mathbf{b} ως προς του παράγοντες φίλτρου:

Παλινδρόμηση κύριων συνιστωσών

Η παλινδρόμηση κύριων συνιστωσών (principal component regression, PCR) βασίζεται στην ανάλυση κύριων συνιστωσών (PCA):

1. Περιστροφή της φυσικής βάσης του \mathbf{R}^K : με PCA (ή SVD) υπολογίζονται οι K κύριες συνιστώσες (principal components, PCs), $\mathbf{X} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$ (όπως για OLS).
2. Προβολή στον υποχώρο \mathbf{R}^k , $k \leq r$: Επιλέγονται οι k πρώτες PCs από κάποιο κριτήριο, π.χ. ποσοστό διασποράς που εξηγείται.
3. Εκτίμηση του μοντέλου παλινδρόμησης στις επιλεγμένες k PCs και εύρεση του διανύσματος συντελεστών.
4. Μετασχηματισμός του διανύσματος συντελεστών πίσω στον αρχικό χώρο των K ανεξάρτητων μεταβλητών.

Η εκτίμηση PCR του \mathbf{b} ως προς του παράγοντες φίλτρου:

$$\mathbf{b}_{\text{PCR}} = \sum_{i=1}^k \frac{\lambda_i}{\sigma_i} (\mathbf{u}_i^T \mathbf{y}) \mathbf{v}_i \quad \lambda_{k+1} = \dots = \lambda_r = 0$$

Παλινδρόμηση κύριων συνιστωσών

Η παλινδρόμηση κύριων συνιστωσών (principal component regression, PCR) βασίζεται στην ανάλυση κύριων συνιστωσών (PCA):


1. Περιστροφή της φυσικής βάσης του \mathbf{R}^K : με PCA (ή SVD) υπολογίζονται οι K κύριες συνιστώσες (principal components, PCs), $\mathbf{X} = \mathbf{U}\Sigma\mathbf{V}^T$ (όπως για OLS).
2. Προβολή στον υποχώρο \mathbf{R}^k , $k \leq r$: Επιλέγονται οι k πρώτες PCs από κάποιο κριτήριο, π.χ. ποσοστό διασποράς που εξηγείται.
3. Εκτίμηση του μοντέλου παλινδρόμησης στις επιλεγμένες k PCs και εύρεση του διανύσματος συντελεστών.
4. Μετασχηματισμός του διανύσματος συντελεστών πίσω στον αρχικό χώρο των K ανεξάρτητων μεταβλητών.

Η εκτίμηση PCR του \mathbf{b} ως προς του παράγοντες φίλτρου:

$$\mathbf{b}_{\text{PCR}} = \sum_{i=1}^k \frac{\lambda_i}{\sigma_i} (\mathbf{u}_i^T \mathbf{y}) \mathbf{v}_i \quad \lambda_{k+1} = \dots = \lambda_r = 0$$

Υπόθεση για την επιλογή k : Η προβολή του \mathbf{y} στις $r - k$ τελευταίες στήλες του \mathbf{U} είναι κάτω από το επίπεδο του θορύβου.

PCR



Πλεονεκτήματα του PCR:

Πλεονεκτήματα του PCR:

- ▶ Μπορεί να μειώσει αποτελεσματικά τη διάσταση, $k \ll r$. Με αυτόν τον τρόπο το PCR μειώνει την υπερ-προσαρμογή που οφείλεται στην ύπαρξη πολλών μεταβλητών στο μοντέλο.

Πλεονεκτήματα του PCR:

- ▶ Μπορεί να μειώσει αποτελεσματικά τη διάσταση, $k \ll r$. Με αυτόν τον τρόπο το PCR μειώνει την υπερ-προσαρμογή που οφείλεται στην ύπαρξη πολλών μεταβλητών στο μοντέλο.
- ▶ Αντιμετωπίζει την πολυ-συγγραμμικότητα. Οι ισχυρά συσχετισμένες μεταβλητές θα αντικατασταθούν με μια PC.

Πλεονεκτήματα του PCR:

- ▶ Μπορεί να μειώσει αποτελεσματικά τη διάσταση, $k \ll r$. Με αυτόν τον τρόπο το PCR μειώνει την υπερ-προσαρμογή που οφείλεται στην ύπαρξη πολλών μεταβλητών στο μοντέλο.
- ▶ Αντιμετωπίζει την πολυ-συγγραμμικότητα. Οι ισχυρά συσχετισμένες μεταβλητές θα αντικατασταθούν με μια PC.
- ▶ Έχει μια μόνο ελεύθερη παράμετρο, k .

Πλεονεκτήματα του PCR:

- ▶ Μπορεί να μειώσει αποτελεσματικά τη διάσταση, $k \ll r$. Με αυτόν τον τρόπο το PCR μειώνει την υπερ-προσαρμογή που οφείλεται στην ύπαρξη πολλών μεταβλητών στο μοντέλο.
- ▶ Αντιμετωπίζει την πολυ-συγγραμμικότητα. Οι ισχυρά συσχετισμένες μεταβλητές θα αντικατασταθούν με μια PC.
- ▶ Έχει μια μόνο ελεύθερη παράμετρο, k .
- ▶ Μπορεί να εφαρμοσθεί και για $K > n$.

Πλεονεκτήματα του PCR:

- ▶ Μπορεί να μειώσει αποτελεσματικά τη διάσταση, $k \ll r$. Με αυτόν τον τρόπο το PCR μειώνει την υπερ-προσαρμογή που οφείλεται στην ύπαρξη πολλών μεταβλητών στο μοντέλο.
- ▶ Αντιμετωπίζει την πολυ-συγγραμμικότητα. Οι ισχυρά συσχετισμένες μεταβλητές θα αντικατασταθούν με μια PC.
- ▶ Έχει μια μόνο ελεύθερη παράμετρο, k .
- ▶ Μπορεί να εφαρμοσθεί και για $K > n$.

Μειονεκτήματα του PCR:

Πλεονεκτήματα του PCR:

- ▶ Μπορεί να μειώσει αποτελεσματικά τη διάσταση, $k \ll r$. Με αυτόν τον τρόπο το PCR μειώνει την υπερ-προσαρμογή που οφείλεται στην ύπαρξη πολλών μεταβλητών στο μοντέλο.
- ▶ Αντιμετωπίζει την πολυ-συγγραμμικότητα. Οι ισχυρά συσχετισμένες μεταβλητές θα αντικατασταθούν με μια PC.
- ▶ Έχει μια μόνο ελεύθερη παράμετρο, k .
- ▶ Μπορεί να εφαρμοσθεί και για $K > n$.

Μειονεκτήματα του PCR:

- ▶ Στη μείωση διάστασης δεν συμμετέχει η εξαρτημένη μεταβλητή. Οι PCs του PCA μπορεί να μην έχουν προβλεπτική ισχύ αντίστοιχη με αυτήν του συνόλου των K ανεξαρτήτων μεταβλητών. Το y μπορεί ακόμα και να είναι κάθετο στον υποχώρο που ορίζεται από τις k πρώτες στήλες του U .

Πλεονεκτήματα του PCR:

- ▶ Μπορεί να μειώσει αποτελεσματικά τη διάσταση, $k \ll r$. Με αυτόν τον τρόπο το PCR μειώνει την υπερ-προσαρμογή που οφείλεται στην ύπαρξη πολλών μεταβλητών στο μοντέλο.
- ▶ Αντιμετωπίζει την πολυ-συγγραμμικότητα. Οι ισχυρά συσχετισμένες μεταβλητές θα αντικατασταθούν με μια PC.
- ▶ Έχει μια μόνο ελεύθερη παράμετρο, k .
- ▶ Μπορεί να εφαρμοσθεί και για $K > n$.

Μειονεκτήματα του PCR:

- ▶ Στη μείωση διάστασης δεν συμμετέχει η εξαρτημένη μεταβλητή. Οι PCs του PCA μπορεί να μην έχουν προβλεπτική ισχύ αντίστοιχη με αυτήν του συνόλου των K ανεξαρτήτων μεταβλητών. Το y μπορεί ακόμα και να είναι κάθετο στον υποχώρο που ορίζεται από τις k πρώτες στήλες του U .
- ▶ Η υπόθεση πως **συνιστώσες μικρής διασποράς έχουν και μικρή προβλεπτική ισχύ σε σχέση με συνιστώσες μεγάλης διασποράς** δεν είναι πάντα ορθή.

Πλεονεκτήματα του PCR:

- ▶ Μπορεί να μειώσει αποτελεσματικά τη διάσταση, $k \ll r$. Με αυτόν τον τρόπο το PCR μειώνει την υπερ-προσαρμογή που οφείλεται στην ύπαρξη πολλών μεταβλητών στο μοντέλο.
- ▶ Αντιμετωπίζει την πολυ-συγγραμμικότητα. Οι ισχυρά συσχετισμένες μεταβλητές θα αντικατασταθούν με μια PC.
- ▶ Έχει μια μόνο ελεύθερη παράμετρο, k .
- ▶ Μπορεί να εφαρμοσθεί και για $K > n$.

Μειονεκτήματα του PCR:

- ▶ Στη μείωση διάστασης δεν συμμετέχει η εξαρτημένη μεταβλητή. Οι PCs του PCA μπορεί να μην έχουν προβλεπτική ισχύ αντίστοιχη με αυτήν του συνόλου των K ανεξαρτήτων μεταβλητών. Το y μπορεί ακόμα και να είναι κάθετο στον υποχώρο που ορίζεται από τις k πρώτες στήλες του U .
- ▶ Η υπόθεση πως **συνιστώσες μικρής διασποράς έχουν και μικρή προβλεπτική ισχύ σε σχέση με συνιστώσες μεγάλης διασποράς** δεν είναι πάντα ορθή.
- ▶ Όταν οι ανεξάρτητες μεταβλητές είναι σε διαφορετικές κλίμακες τιμών θα πρέπει να τυποποιηθούν πριν την εφαρμογή του PCA. ☹ ☹ ☹

Παλινδρόμηση με μερικά ελάχιστα τετράγωνα

Η παλινδρόμηση με μερικά ελάχιστα τετράγωνα (principal least square, PLS) προσπαθεί να μετασχηματίσει το X ώστε να μεγιστοποιηθεί η συνδιασπορά του με το Y .

Παλινδρόμηση με μερικά ελάχιστα τετράγωνα

Η παλινδρόμηση με μερικά ελάχιστα τετράγωνα (principal least square, PLS) προσπαθεί να μετασχηματίσει το X ώστε να μεγιστοποιηθεί η συνδιασπορά του με το Y .

$$X = TP^T + E,$$

T : $n \times k$ πίνακας των k κρυφών διανυσμάτων (scores) του X .

P : $K \times k$ πίνακας των k μετασχηματισμένων κρυφών μεταβλητών (loadings). E : $n \times K$ πίνακας υπολοίπων

Παλινδρόμηση με μερικά ελάχιστα τετράγωνα

Η παλινδρόμηση με μερικά ελάχιστα τετράγωνα (principal least square, PLS) προσπαθεί να μετασχηματίσει το X ώστε να μεγιστοποιηθεί η συνδιασπορά του με το Y .

$$X = TP^T + E,$$

T : $n \times k$ πίνακας των k κρυφών διανυσμάτων (scores) του X .

P : $K \times k$ πίνακας των k μετασχηματισμένων κρυφών μεταβλητών (loadings). E : $n \times K$ πίνακας υπολοίπων

Έχουν αναπτυχθεί διάφοροι αλγόριθμοι για την υλοποίηση του PLS.

Παλινδρόμηση με μερικά ελάχιστα τετράγωνα

Η παλινδρόμηση με μερικά ελάχιστα τετράγωνα (principal least square, PLS) προσπαθεί να μετασχηματίσει το X ώστε να μεγιστοποιηθεί η συνδιασπορά του με το Y .

$$X = TP^T + E,$$

T : $n \times k$ πίνακας των k κρυφών διανυσμάτων (scores) του X .

P : $K \times k$ πίνακας των k μετασχηματισμένων κρυφών μεταβλητών (loadings). E : $n \times K$ πίνακας υπολοίπων

Έχουν αναπτυχθεί διάφοροι αλγόριθμοι για την υλοποίηση του PLS.

Η εκτίμηση PLS του b ως προς τους παράγοντες φίλτρου (μετασχηματίζοντας τον υποχώρο R^k στον χώρο R^r που ορίζεται από τη βάση των ιδιάζοντων διανυσμάτων):

Παλινδρόμηση με μερικά ελάχιστα τετράγωνα

Η παλινδρόμηση με μερικά ελάχιστα τετράγωνα (principal least square, PLS) προσπαθεί να μετασχηματίσει το X ώστε να μεγιστοποιηθεί η συνδιασπορά του με το Y .

$$X = TP^T + E,$$

T : $n \times k$ πίνακας των k κρυφών διανυσμάτων (scores) του X .

P : $K \times k$ πίνακας των k μετασχηματισμένων κρυφών μεταβλητών (loadings). E : $n \times K$ πίνακας υπολοίπων

Έχουν αναπτυχθεί διάφοροι αλγόριθμοι για την υλοποίηση του PLS.


Η εκτίμηση PLS του \mathbf{b} ως προς τους παράγοντες φίλτρου (μετασχηματίζοντας τον υποχώρο \mathbf{R}^k στον χώρο \mathbf{R}^r που ορίζεται από τη βάση των ιδιάζοντων διανυσμάτων):

$$\mathbf{b}_{\text{PLS}} = \sum_{i=1}^r \frac{\lambda_i}{\sigma_i} (\mathbf{u}_i^T \mathbf{y}) \mathbf{v}_i \quad \lambda_i = 1 - \prod_{j=1}^q (1 - \frac{\sigma_j^2}{\theta_j}),$$


όπου $\theta_1 \geq \theta_2 \geq \dots \geq \theta_r$ είναι οι Ritz τιμές (πολύπλοκες εκφράσεις)

Ενώ τα λ_i για $i = k + 1, \dots, r$ δεν είναι 0, έχουμε $\|\mathbf{b}_{\text{PLS}}\|_2 \leq \|\mathbf{b}_{\text{PCR}}\|_2$

PCR



PLS



Πλεονεκτήματα της PLS:

Πλεονεκτήματα της PLS:

- ▶ Μπορεί να εφαρμοσθεί και για πολλαπλές εξαρτημένες μεταβλητές.

Πλεονεκτήματα της PLS:

- ▶ Μπορεί να εφαρμοσθεί και για πολλαπλές εξαρτημένες μεταβλητές.
- ▶ Αντιμετωπίζει αποτελεσματικά τη συγγραμμικότητα.

Πλεονεκτήματα της PLS:

- ▶ Μπορεί να εφαρμοσθεί και για πολλαπλές εξαρτημένες μεταβλητές.
- ▶ Αντιμετωπίζει αποτελεσματικά τη συγγραμμικότητα.
- ▶ Στη μείωση διάστασης (κανονικοποίηση) **συμμετέχει** η εξαρτημένη μεταβλητή και για αυτό το μοντέλο έχει μεγάλη προβλεπτική ισχύ.

Πλεονεκτήματα της PLS:

- ▶ Μπορεί να εφαρμοσθεί και για πολλαπλές εξαρτημένες μεταβλητές.
- ▶ Αντιμετωπίζει αποτελεσματικά τη συγγραμμικότητα.
- ▶ Στη μείωση διάστασης (κανονικοποίηση) **συμμετέχει** η εξαρτημένη μεταβλητή και για αυτό το μοντέλο έχει μεγάλη προβλεπτική ισχύ.

Μειονεκτήματα PLS:

Πλεονεκτήματα της PLS:

- ▶ Μπορεί να εφαρμοσθεί και για πολλαπλές εξαρτημένες μεταβλητές.
- ▶ Αντιμετωπίζει αποτελεσματικά τη συγγραμμικότητα.
- ▶ Στη μείωση διάστασης (κανονικοποίηση) **συμμετέχει** η εξαρτημένη μεταβλητή και για αυτό το μοντέλο έχει μεγάλη προβλεπτική ισχύ.

Μειονεκτήματα PLS:

- ▶ Είναι δύσκολο να ερμηνεύσουμε του συντελεστές των k μετασχηματισμένων μεταβλητών στον πίνακα P (loadings).

Πλεονεκτήματα της PLS:

- ▶ Μπορεί να εφαρμοσθεί και για πολλαπλές εξαρτημένες μεταβλητές.
- ▶ Αντιμετωπίζει αποτελεσματικά τη συγραμμικότητα.
- ▶ Στη μείωση διάστασης (κανονικοποίηση) **συμμετέχει** η εξαρτημένη μεταβλητή και για αυτό το μοντέλο έχει μεγάλη προβλεπτική ισχύ.

Μειονεκτήματα PLS:

- ▶ Είναι δύσκολο να ερμηνεύσουμε του συντελεστές των k μετασχηματισμένων μεταβλητών στον πίνακα P (loadings).
- ▶ Η κατανομή των εκτιμητών \mathbf{b} και \hat{y} δεν είναι γνωστές και δε μπορεί να γίνει παραμετρικά η συμπερασματολογία (διαστήματα εμπιστοσύνης και έλεγχοι υπόθεσης).

Παλινδρόμηση ridge

Η παλινδρόμηση ridge (RR) συρρικνώνει του συντελεστές παλινδρόμησης (τα στοιχεία του \mathbf{b}) προς το 0 επιβάλλοντας ποινή στο $\|\mathbf{b}\|_2$.

Η παλινδρόμηση ridge (RR) συρρικνώνει του συντελεστές παλινδρόμησης (τα στοιχεία του \mathbf{b}) προς το 0 επιβάλλοντας ποινή στο $\|\mathbf{b}\|_2$.

RR ελαχιστοποιεί τη συνάρτηση κόστους

$$\mathbf{b}_{RR} = \arg \max_{\beta} \|\mathbf{y} - X\beta\|_2^2 + \mu \|\beta\|_2^2$$

όπου $\mu > 0$ είναι η παράμετρος κανονικοποίησης που ελέγχει την επίδραση του όρου ποινής.

Παλινδρόμηση ridge

Η παλινδρόμηση ridge (RR) συρρικνώνει του συντελεστές παλινδρόμησης (τα στοιχεία του \mathbf{b}) προς το 0 επιβάλλοντας ποινή στο $\|\mathbf{b}\|_2$.

RR ελαχιστοποιεί τη συνάρτηση κόστους

$$\mathbf{b}_{RR} = \arg \max_{\beta} \|\mathbf{y} - X\beta\|_2^2 + \mu \|\beta\|_2^2$$

όπου $\mu > 0$ είναι η παράμετρος κανονικοποίησης που ελέγχει την επίδραση του όρου ποινής.

Η εκτίμηση RR του \mathbf{b} ως προς τους παράγοντες φίλτρου:

Παλινδρόμηση ridge

Η παλινδρόμηση ridge (RR) συρρικνώνει του συντελεστές παλινδρόμησης (τα στοιχεία του \mathbf{b}) προς το 0 επιβάλλοντας ποινή στο $\|\mathbf{b}\|_2$.

RR ελαχιστοποιεί τη συνάρτηση κόστους

$$\mathbf{b}_{\text{RR}} = \arg \max_{\beta} \|\mathbf{y} - X\beta\|_2^2 + \mu \|\beta\|_2^2$$

όπου $\mu > 0$ είναι η παράμετρος κανονικοποίησης που ελέγχει την επίδραση του όρου ποινής.

Η εκτίμηση RR του \mathbf{b} ως προς τους παράγοντες φίλτρου:

$$\mathbf{b}_{\text{RR}} = \sum_{i=1}^r \frac{\lambda_i}{\sigma_i} (\mathbf{u}_i^T \mathbf{y}) \mathbf{v}_i \quad \lambda_i = \frac{\sigma_i^2}{\sigma_i^2 + \mu}$$

+ Το RR αποδίδει καλά ως προς την ακρίβεια πρόβλεψης.

- + Το RR αποδίδει καλά ως προς την ακρίβεια πρόβλεψης.
- Η εφαρμογή του RR βασίζεται κύρια στην επιλογή του μ .

+ Το RR αποδίδει καλά ως προς την ακρίβεια πρόβλεψης.

— Η εφαρμογή του RR βασίζεται κύρια στην επιλογή του μ .

Κατάλληλη επιλογή για μ είναι η εκτίμηση της διασποράς των υπολοίπων από την εκτίμηση της παλινδρόμησης με OLS, που ισοδύναμα δίνεται ως

$$\mu = s_e^2 = \frac{1}{n-r} \sum_{i=r+1}^n (\mathbf{u}_i^T \mathbf{y})^2$$

+ Το RR αποδίδει καλά ως προς την ακρίβεια πρόβλεψης.

— Η εφαρμογή του RR βασίζεται κύρια στην επιλογή του μ .

Κατάλληλη επιλογή για μ είναι η εκτίμηση της διασποράς των υπολοίπων από την εκτίμηση της παλινδρόμησης με OLS, που ισοδύναμα δίνεται ως

$$\mu = s_e^2 = \frac{1}{n-r} \sum_{i=r+1}^n (\mathbf{u}_i^T \mathbf{y})^2$$

— Το RR δεν επιτελεί επιλογή μεταβλητών (μείωση διάστασης).

+ Το RR αποδίδει καλά ως προς την ακρίβεια πρόβλεψης.

— Η εφαρμογή του RR βασίζεται κύρια στην επιλογή του μ .

Κατάλληλη επιλογή για μ είναι η εκτίμηση της διασποράς των υπολοίπων από την εκτίμηση της παλινδρόμησης με OLS, που ισοδύναμα δίνεται ως

$$\mu = s_e^2 = \frac{1}{n-r} \sum_{i=r+1}^n (\mathbf{u}_i^T \mathbf{y})^2$$

— Το RR δεν επιτελεί επιλογή μεταβλητών (μείωση διάστασης).

— Είναι δύσκολο να ερμηνευθεί το RR.

Το RR ελαχιστοποιεί τη συνάρτηση κόστους

$$\mathbf{b}_{\text{RR}} = \arg \max_{\beta} \|\mathbf{y} - X\beta\|_2^2 + \mu \|\beta\|_2^2$$

Οι συντελεστές στο διάνυσμα \mathbf{b}_{RR} συρρικνώνονται αλλά δε γίνονται 0.

Το RR ελαχιστοποιεί τη συνάρτηση κόστους

$$\mathbf{b}_{\text{RR}} = \arg \max_{\beta} \|\mathbf{y} - X\beta\|_2^2 + \mu \|\beta\|_2^2$$

Οι συντελεστές στο διάνυσμα \mathbf{b}_{RR} συρρικνώνονται αλλά δε γίνονται 0.

Η μέθοδος LASSO (Least Absolute Selection and Shrinkage Operator) θέτει τους συντελεστές του \mathbf{b} σε 0 επιβάλλοντας ποινή στο $\|\mathbf{b}\|_1$.

Το RR ελαχιστοποιεί τη συνάρτηση κόστους

$$\mathbf{b}_{\text{RR}} = \arg \max_{\beta} \|\mathbf{y} - X\beta\|_2^2 + \mu \|\beta\|_2^2$$

Οι συντελεστές στο διάνυσμα \mathbf{b}_{RR} συρρικνώνονται αλλά δε γίνονται 0.

Η μέθοδος LASSO (Least Absolute Selection and Shrinkage Operator) θέτει τους συντελεστές του \mathbf{b} σε 0 επιβάλλοντας ποινή στο $\|\mathbf{b}\|_1$.

Η LASSO ελαχιστοποιεί τη συνάρτηση κόστους

$$\mathbf{b}_{\text{LASSO}} = \arg \max_{\beta} \|\mathbf{y} - X\beta\|_2^2 + \mu \|\beta\|_1, \quad \|\beta\|_1 = \sum_i^r |\beta_i|$$

$$\mu = 0 \Rightarrow \text{OLS} \quad \mu = \infty \Rightarrow \mathbf{b}_{\text{LASSO}} = \mathbf{0}$$

Το RR ελαχιστοποιεί τη συνάρτηση κόστους

$$\mathbf{b}_{\text{RR}} = \arg \max_{\beta} \|\mathbf{y} - X\beta\|_2^2 + \mu \|\beta\|_2^2$$

Οι συντελεστές στο διάνυσμα \mathbf{b}_{RR} συρρικνώνονται αλλά δε γίνονται 0.

Η μέθοδος LASSO (Least Absolute Selection and Shrinkage Operator) θέτει τους συντελεστές του \mathbf{b} σε 0 επιβάλλοντας ποινή στο $\|\mathbf{b}\|_1$.

Η LASSO ελαχιστοποιεί τη συνάρτηση κόστους

$$\mathbf{b}_{\text{LASSO}} = \arg \max_{\beta} \|\mathbf{y} - X\beta\|_2^2 + \mu \|\beta\|_1, \quad \|\beta\|_1 = \sum_i^r |\beta_i|$$

$$\mu = 0 \Rightarrow \text{OLS} \quad \mu = \infty \Rightarrow \mathbf{b}_{\text{LASSO}} = \mathbf{0}$$

+ Η LASSO εφαρμόζει επιλογή μεταβλητών (μείωση διάστασης) σύμφωνα με την τιμή του $\mu > 0$ και είναι εύκολο να ερμηνευθεί.

Το RR ελαχιστοποιεί τη συνάρτηση κόστους

$$\mathbf{b}_{\text{RR}} = \arg \max_{\beta} \|\mathbf{y} - X\beta\|_2^2 + \mu \|\beta\|_2^2$$

Οι συντελεστές στο διάνυσμα \mathbf{b}_{RR} συρρικνώνονται αλλά δε γίνονται 0.

Η μέθοδος LASSO (Least Absolute Selection and Shrinkage Operator) θέτει τους συντελεστές του \mathbf{b} σε 0 επιβάλλοντας ποινή στο $\|\mathbf{b}\|_1$.

Η LASSO ελαχιστοποιεί τη συνάρτηση κόστους

$$\mathbf{b}_{\text{LASSO}} = \arg \max_{\beta} \|\mathbf{y} - X\beta\|_2^2 + \mu \|\beta\|_1, \quad \|\beta\|_1 = \sum_i^r |\beta_i|$$

$$\mu = 0 \Rightarrow \text{OLS} \quad \mu = \infty \Rightarrow \mathbf{b}_{\text{LASSO}} = \mathbf{0}$$

+ Η LASSO εφαρμόζει επιλογή μεταβλητών (μείωση διάστασης) σύμφωνα με την τιμή του $\mu > 0$ και είναι εύκολο να ερμηνευθεί.

+ Η LASSO αποδίδει καλά ως προς την ακρίβεια πρόβλεψης.

LASSO

Το RR ελαχιστοποιεί τη συνάρτηση κόστους

$$\mathbf{b}_{\text{RR}} = \arg \max_{\beta} \|\mathbf{y} - X\beta\|_2^2 + \mu \|\beta\|_2^2$$

Οι συντελεστές στο διάνυσμα \mathbf{b}_{RR} συρρικνώνονται αλλά δε γίνονται 0.

Η μέθοδος LASSO (Least Absolute Selection and Shrinkage Operator) θέτει τους συντελεστές του \mathbf{b} σε 0 επιβάλλοντας ποινή στο $\|\mathbf{b}\|_1$.

Η LASSO ελαχιστοποιεί τη συνάρτηση κόστους

$$\mathbf{b}_{\text{LASSO}} = \arg \max_{\beta} \|\mathbf{y} - X\beta\|_2^2 + \mu \|\beta\|_1, \quad \|\beta\|_1 = \sum_i^r |\beta_i|$$

$$\mu = 0 \Rightarrow \text{OLS} \quad \mu = \infty \Rightarrow \mathbf{b}_{\text{LASSO}} = \mathbf{0}$$

+ Η LASSO εφαρμόζει επιλογή μεταβλητών (μείωση διάστασης) σύμφωνα με την τιμή του $\mu > 0$ και είναι εύκολο να ερμηνευθεί.

+ Η LASSO αποδίδει καλά ως προς την ακρίβεια πρόβλεψης.

— Η επίδοση της LASSO βασίζεται στην επιλογή της παραμέτρου μ .

5. Δημιουργήστε τον πίνακα δεδομένων X μεγέθους $n \times p$ από $p = 5$ μεταβλητές που ακολουθούν εκθετική κατανομή με διαφορετικές μέσες τιμές η κάθε μια (ελεύθερη επιλογή). Δημιουργήστε το διάνυσμα απόκρισης y από τη σχέση $y = X\beta + \epsilon$, όπου το διάνυσμα συντελεστών β έχει μόνο δύο μη-μηδενικά στοιχεία, π.χ. $\beta = [0, 2, 0, -3, 0]^T$, και η τυχαία μεταβλητή θορύβου, που δίνει τις τιμές στο ϵ , ακολουθεί κανονική κατανομή με δεδομένη τυπική απόκλιση, π.χ. $\sigma_\epsilon = 5$.
- (α) Εκτιμήστε το μοντέλο πολλαπλής γραμμικής παλινδρόμησης με κάθε μια από τις μεθόδους OLS, PCR, PLS, RR και LASSO.
- (β) Για κάθε μέθοδο σχηματίστε το διάγραμμα διασποράς των παρατηρούμενων και εκτιμώμενων τιμών της εξαρτημένης μεταβλητής καθώς και το διάγραμμα των τυποποιημένων σφαλμάτων παλινδρόμησης.
- (γ) Συγκρίνετε τις εκτιμήσεις του β με κάθε μια μέθοδο.
6. Στην Άσκηση 5.8 εκτιμήσαμε το μοντέλο γραμμικής παλινδρόμησης με την OLS και τη βηματική παλινδρόμηση, όπου χρησιμοποιήθηκαν τα δεδομένα στο αρχείο `physical.txt`. Στα ίδια δεδομένα εκτιμήστε το μοντέλο γραμμικής παλινδρόμησης με τις μεθόδους PCR, PLS, RR και LASSO. Συγκρίνετε τα αποτελέσματα με αυτά των OLS και βηματικής παλινδρόμησης.